

IPO 信息披露冗余复刻审计报告

基于 cot_v3b_len132_tight 全 543 家样本与原文表 1/表 2 的描述性对比

日期：2026-07-05 项目：IPO 信息披露冗余如何影响新股定价复刻

摘要

本文档对当前本地复刻结果与原文描述性统计及 Table 2 经济后果回归进行审计。结论是：cot_v3b_len132_tight 已经可以作为当前主 X 口径进入下一阶段审计；企业层 Redundancy 均值为 29.374，与原文 29.074 接近，chunk 层 Summary_len 与 Redundancy_chunk 也已贴近原文。但 Table 2 strict replication 仍为 NO_PASS_YET。主要缺口已经从 prompt 或摘要长度转向 empirical layer，包括 Underwriter 构造错误、NumIndSeg/NumProdSeg/ScopeLen 缺失、FSales_Growth 口径偏差、lnN_tech 长度单位与 552 到 471 样本链条未对齐。

关键词：IPO 信息披露冗余；生成式人工智能；描述性统计复刻；Table 2；控制变量审计

当前判定

X 变量维度：LOCK_X_MEASUREMENT_FOR_NEXT_EMPIRICAL_AUDIT Table 2 strict replication：NO_PASS_YET

一、审计背景与 major correction

本轮审计首先修正了一个关键口径错误：旧 master 中的大写 Redundancy 并不是 cot_v3b_len132_tight 的企业层 X。若直接使用该列运行 Table 2，会把旧 scoregate 口径误认为 len132_tight。现已显式合并 firm_ranking_cot_v3b_len132_tight_20260703.csv，并将其作为唯一 X 来源。这个修正使 FInvention 与 BHAR 的系数回到原文方向，但幅度和显著性仍不足，FSales_Growth 仍为反号。

因此，当前结论不是 X prompt 崩坏，而是 X 测度已经足够进入下一阶段，真正瓶颈在 Y、controls、样本 waterfall 与数据库字段。后续文件必须保留 x_source、x_file、x_merge_key、x_N 与 x_mean，以避免再次发生 X provenance 混淆。

二、文本块层面描述性统计对比

表 1 文本块层面描述性统计：当前口径 vs 原文

变量	当前N	原文N	当前均值	原文均值	差值	差异率	当前中位数	原文中位数
Chunk_num	7028	8683	14.054	18.191	-4.137	-22.7%	14.000	16.000
Text_len	7028	8683	3758.194	3866.817	-108.623	-2.8%	3940.000	3954.000
Summary_len	7028	8683	128.253	132.678	-4.425	-3.3%	128.000	130.000
Redundancy_chunk	7028	8683	30.708	32.176	-1.468	-4.6%	29.955	29.739

注：当前口径为 cot_v3b_len132_tight 全 543 家；原文为 552 家、8683 个文本块。差异率按均值差值除以原文均值计算。

表 1 显示，Summary_len 当前均值 128.253，原文 132.678；Redundancy_chunk 当前均值 30.708，原文 32.176。这说明摘要长度校准已经基本成功。更值得注意的是 Chunk_num 当前 14.054，原文 18.191，且当前 chunk 总数为 7028，比原文少 1655 个。这个差距更可能来自样本企业缺失、章节抽取边界或切块规则

，而不是模型摘要长度本身。

三、企业层描述性统计对比

表 2 企业层主要变量描述性统计：当前口径 vs 原文

变量	当前可得	当前N	原文N	当前均值	原文均值	差值	差异率
lnN_tech	是	543	552	10.745	10.962	-0.217	-2.0%
Redundancy	是	543	552	29.374	29.074	0.300	1.0%
FInvention	是	531	471	2.325	2.282	0.043	1.9%
BHAR	是	541	471	-0.062	-0.036	-0.026	-71.6%
FSales_Growth	是	538	471	0.409	0.530	-0.121	-22.8%
RD_Asset	是	541	552	0.079	0.105	-0.026	-25.1%
Size	是	541	552	20.779	20.741	0.038	0.2%
Lev	是	541	552	0.360	0.356	0.004	1.1%
ROA	是	541	552	0.091	0.094	-0.003	-3.7%
Offerfee	是	542	552	18.327	18.325	0.002	0.0%
Underwriter	是	543	552	0.009	0.574	-0.565	-98.4%
Age	是	541	552	2.612	2.601	0.011	0.4%
NumIndSeg	否	0	552		0.854		
NumProdSeg	否	0	552		1.475		
ScopeLen	否	0	552		5.671		

注：空白表示当前 master 未构造该变量。Underwriter 当前均值仅 0.009，源于临时 CSMAR 表 Sponsor 字段大多为 None。

企业层 X 的均值已经贴近原文：Redundancy 当前 29.374，原文 29.074。但 lnN_tech 当前 10.745，低于原文 10.962；换算后当前原始长度约为原文口径的 80.5%。这说明文本长度单位或业务与技术章节抽取边界仍需审计。Controls 方面，Underwriter 与 NumIndSeg、NumProdSeg、ScopeLen 是最大缺口，当前回归不能称为原文 Table 2 的 strict replication。

四、Table 2 接入审计结果

表 3 Table 2 Panel B 主规格回归对比

被解释变量	当前N	当前coef	当前t	当前p	原文coef	原文t	方向
FInvention	531	-0.0091	-0.58	0.561	-0.0316	-1.72	同号
BHAR	541	-0.0051	-0.66	0.508	-0.0188	-2.14	同号
FSales_Growth	538	0.0281	1.38	0.168	-0.0373	-2.02	反号

注：当前规格为 Outcome ~ Redundancy + lnN_tech + Size + Lev + ROA + Offerfee + Underwriter + Age + Year FE + Industry FE, HC1 robust 标准误。

接入真正的 len132_tight X 后，FInvention 与 BHAR 回到负号，但系数约只有原文的三分之一左右且不显著；FSales_Growth 仍为正号。共同样本与 2019-2022 窗口也不能把三项同时推回原文结果。这说明 Table 2 失败不应优先反推 X 测度失败，而应优先检查 outcome 与 controls 口径。

五、当前 replication gap 的优先级

表 4 下一阶段审计任务优先级

顺序	对象	当前问题	建议动作
1	Underwriter	当前均值 0.009，原文 0.574；Sponsor 字段几乎全空	从 Choice 或可替代 IPO 承销数据库重构主承销商/保荐机构 top10 dummy
2	NumIndSeg / NumProdSeg / ScopeLen	原文明确控制，当前完全缺失	补齐业务分部、产品分部、经营范围长度；先复现 Panel A 均值
3	FSales_Growth	当前均值 0.409，原文 0.530；回归仍反号	做 t+1/t、完整会计年度、字段来源、winsor、471 样本网格
4	lnN_tech	当前 10.745，原文 10.962；原始长度约为原文的 80.5%	并行比较原始字符、去空白字符、中文字数、token proxy
5	552 -> 471 crosswalk	当前 543/541/528，与原文 552/471 未对齐	逐家公司列出 X、上市年、三个 Y、controls 和最终样本进入情况

注：这些任务应先于任何新的 prompt 调参或 LLM 重跑。

六、结论

当前最稳妥的研究状态表述是：cot_v3b_len132_tight 已锁定为下一阶段 empirical audit 的主 X 口径，暂停 prompt、tailfix 与 summary length 调参。Table 2 strict replication 仍未通过，不能宣称复刻原文经济后果。下一阶段主战场是 Choice/CSMAR 字段、原文 controls、Y 变量口径与样本 waterfall。

若后续 Underwriter 与三项 paper-only controls 补齐后，FInvention 与 BHAR 仍保持负号但较弱，而 FSales_Growth 仍反号，则应优先重查 FSales_Growth 的会计年度口径与 winsor 处理，而不是回头重建 X。

数据来源与输出文件

主要输入：descriptive_comparison_vs_original_20260705、table2_len132_tight_audit_20260705、summary_len_calibration_full_543_20260704。原文锚点来自本地 PDF 的表 1 与表 2。